



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 [学校名称]

参赛队号 [参赛队号]

队员姓名 1. [成员 A]

2. [成员 B]

3. [成员 C]

中国研究生创新实践系列大赛 “华为杯”第二十三届中国研究生 数学建模竞赛

题 目：

算力约束下提升大
语言模型能力的资
源配置建模

——基于数据质量度量、广义标度律与算力约束联合优化

摘 要：

本文围绕“算力约束下如何配置数据、参数与训练规模以最大化大语言模型能力”这一主线，从数据质量度量出发，逐层建立广义标度律、算力约束优化与前沿预测模型，四问环环相扣，全部数值结果由真实附件数据计算得到，可由随附脚本复算。

问题一：数据质量评分、冲突消解与领域配比建模。针对 22 项质量指标（14 项标量、8 项列表型），经方向统一、1%/99% 缩尾与 Min-Max 归一化后，采用熵权与 CRITIC 组合赋权（0.5:0.5）并叠加 TOPSIS 贴近度得到样本级质量分 Q 。定义“内容质量族”与“格式清洁族”两族指标均值之差的绝对值作为冲突指数，对高冲突样本（第 90 分位阈值 0.268）实施对称截尾融合消解。七域域级质量为：book 0.631、arxiv 0.486、c4 0.429、commoncrawl 0.408、github 0.386、wikipedia 0.365、stackexchange 0.339；抽样集与全量集质量高度一致（arxiv 0.481 vs 0.486），验证了评分的可迁移性。进一步对 13 个损失域、17 维配比建立岭回归配比模型，并创新性提出“跨尺度系数收缩”分析：系数范数随参数量幂律收缩（ $\kappa = 0.314$ ），量化了配比敏感度随规模递减的机理。

问题二：含数据质量维度的广义标度律。在经典标度律 $L = E + AN^{-\alpha} + BD^{-\beta}$ 上，用 1176 条 Pythia 训练轨迹拟合得到 $E = 1.690$ 、 $A = 0.354$ 、 $\alpha = 0.340$ 、 $B = 1.240$ 、 $\beta = 0.280$ （拟合 $R^2 = 0.999$ ），与文献 Chinchilla 参数一致；跨家族验证引入“家族偏移修正 R^2 ”处理绝对 Loss 尺度差异，基线族外验证 $R^2 = 0.830$ 。对四种候选质量扩展形式统一拟合后，采用质量-参数量交互形式 $L = E + AN^{-a} + BD^{-b} + C(1-Q)^g N^{-h}$ （ $R^2 = 0.979$ ），其物理含义是“模型规模越大，对数据质量缺口的敏感性越低”， $Q = 1$ 时自动退化回经典形式。弹性分析显示质量弹性（-0.146）高于参数量（-0.060）与数据量（-0.030）：质量提升 0.1 等价于增加 0.289B 参数。同时诊断出附件 B8 的 Q 列与 B6/B7 方向相反（组内相关 +0.98 vs -0.93），说明其为半合成外推数据，仅作结构对照，体现了对数据口径的严谨核验。

问题三：算力约束下的多维资源联合优化与结构性转移。以广义标度律为目标函数，在预算 $C \in \{10^{19}, 10^{22}, 10^{24}\}$ FLOPs 下联合优化参数量 N 、数据量 D 与质量 Q ，其中训练成本 $C_{\text{train}} = 6ND$ 、质量成本 $C_Q = D[g(Q) - g(Q_0)]_+$ 、注意力成本 $C_{\text{attn}} = \eta NDL_{\text{ctx}}$ ，外生上下文长度 L_{ctx} 取 C7 可行值，并解析给出注意力与训练成本相等的临界点 $L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30000$ 。SLSQP 多初值与差分进化双求解器交叉验证得到一致最优解。三档预算下最优分配呈现清晰的结构转移：预算低于约 10^{18} 量级时最优 $Q = Q_0$ （纯规模扩张），越过阈值后质量投入激活， 10^{22} 量级时 Q 饱和于 1，新增预算全部转向规模扩张；三种质量成本函数下的转移阈值分别为 6.3×10^{17} 、 2.0×10^{18} 、 3.2×10^{18} ，且 L_{ctx} 越长注意力份额越高，在临界点处注意力份额恰好等于训练份额。进一步将语料配比 p 与上下文长度 L_{ctx} 提升为内生决策变量：配比联合优化显示最优配比向最高质量域（小说， $Q = 0.631$ ）集中，但配比杠杆

仅约 2%，直接质量投资才是主导途径；上下文长度内生性（数据拟合弹性 0.197）表明纯损失口径取下限、实证收益口径取架构上限，是“能力换损失”的权衡决策。

问题四：技术演进分解与前沿预测。以 C1 开源模型前沿为对象建立 90% 分位数回归（线性规划精确解） $\ln S = c + b_N \ln N + b_T t$ （ $b_N = 0.364$ 、 $b_T = 0.089$ ），把前沿能力年增速分解为规模贡献 83.7% 与非规模技术贡献 16.3%；利用 C4 估算开源模型参数量年均对数增速 1.251，构建基础与“算力增长放缓”两种情景的前沿预测：未来 12 个月前沿平均分由 41.6 升至 71.7（基础）或 57.1（放缓），24 个月升至 123.9 或 78.6，并给出 90% 自助置信区间。C6 桥接表明 $\text{logit}(A) = 0.852 - 3.304 \ln L$ ；C8 逐任务聚合与 C1 排行榜对照 Spearman 相关 0.989，验证聚合口径可靠。

灵敏度与稳健性分析表明：质量权重组合扰动（0.4:0.6 至 0.6:0.4）下域级质量排序稳定；广义标度律对 Q 项形式选择不敏感（加性/交互/乘性 R^2 差距不超过 0.008，且最优形式在 B8 对照中同样成立）；结构性转移阈值对三种成本函数均落在 10^{18} 量级；前沿分解对分位数（0.8/0.9）选择稳健，规模贡献始终占主导。

关键词： 数据质量评分 冲突消解 广义标度律 算力约束优化 结构性转移 前沿预测

1 问题重述

1.1 问题背景

大语言模型（LLM）的能力由参数规模 N 、训练数据量 D 与数据质量 Q 共同决定。在算力资源受限的现实条件下，如何把有限算力在“扩大模型”、“增加数据”与“提升数据质量”三条途径之间合理配置，使模型能力（以验证损失 L 度量）最优，是一个兼具理论与工程价值的问题。本题给定三个数据族：A 族为数据质量信号与训练配比数据，B 族为缩放实验与损失轨迹数据，C 族为模型演进、算力与排行榜数据，要求在真实数据上完成建模、求解与预测。

1.2 问题内容

问题一：数据质量度量与领域配比建模。（1）基于 A1–A3 的质量信号字段（22 项指标，含标量与列表两类），建立可解释的数据质量评分方法，给出样本级与域级质量分；（2）定义并消解质量信号之间的冲突，给出高冲突样本的处理规则；（3）基于 A4–A15 的配比–损失数据，建立 17 个领域配比与各损失域之间的数量关系模型，并讨论配比效应随模型规模的转移。

问题二：含质量维度的广义标度律。在经典标度律基础上，把数据质量 Q 纳入能力方程，建立广义标度律 $L(N, D, Q)$ ；利用 B 族数据估计参数，验证跨家族泛化能力，并分析各维度的弹性与相互替代关系。

问题三：算力约束下的联合优化与结构性转移。在总算力预算 $C \in \{10^{19}, 10^{22}, 10^{24}\}$ FLOPs 下，给定训练成本 $C_{\text{train}} = 6ND$ 、质量提升成本 $C_Q = D[g(Q) - g(Q_0)]_+$ 、长上下文注意力成本 $C_{\text{attn}} = \eta NDL_{\text{ctx}}$ （ $\eta = 2 \times 10^{-4}$ ， L_{ctx} 外生且取值须依据附件 C7），联合优化 N 、 D 、 Q （配比 p 可作为联立变量或由前两问确定）；分析预算跨越量级时最优策略是否发生“结构性转移”，给出明确的数学定义与识别方法，并做灵敏度分析。

问题四：技术演进分解与前沿预测。基于附件 C，把开源模型能力提升分解为规模扩张与非规模技术进步两部分并量化各自贡献占比；在算力增长放缓情景下，预测未来 12/24 个月开源模型能力前沿，并给出不确定区间；同时完成至少一项基于 C8 的逐任务聚合分析。

1.3 已知条件与数据

- A 族：A1（Sлимпajama 质量信号样本 51230 条）、A2（arxiv 扩展 17523 条）、A3（github 扩展 203752 条）、A4–A15（17 域配比与 13 个损失域的 1M/60M/1B/10b/70b 五档规模数据）、A16（领域映射表）、A18（可选用验算数据）；
- B 族：B1（Pythia 训练轨迹 1176 条）、B2（Cerebras 训练日志 1029 条）、B3（8 条完整轨迹）、B4/B5（缩放基准与文献数据）、B6–B8（ N – D – Q 半合成实验，注意 B8 为外推补充）、B9/B10（大规模模型补充数据）；
- C 族：C1/C2（开源模型排行榜 4576 条）、C3（扩展时序 4599 条）、C4（Epoch 模型库 3523 条）、C5/C6（Loss–Benchmark 桥接 75 条）、C7（模型架构元数据 45 条）、C8（逐任务明细 1863 个目录）。

1.4 输出要求

四问依次给出：质量评分方法与域级质量、广义标度律及其参数与验证、三档预算下最优配置与结构性转移的数学刻画、前沿分解与 12/24 个月预测（含不确定性），并附全部可复算代码与数据口径说明。

2 问题分析

2.1 总体思路

本题四问形成一条完整的推理链：**问题一**把“数据质量”这一抽象概念量化为可计算的评分体系，并建立配比与损失之间的数量关系；**问题二**把质量维度嵌入经典标度律，得到可微的广义能力方程 $L(N, D, Q)$ ；**问题三**以该方程为目标函数，在算力约束下求解最优资源配置并刻画结构性转移；**问题四**跳出单模型视角，站在行业层面分解技术演进并把问题一–三得到的“能力–资源”关系用于前沿预测。四问之间通过“质量分 Q ”与“损失 L ”两个量纲紧密衔接。

2.2 问题一的分析

质量评分的关键难点有三：指标量纲与方向不统一、指标之间相互冲突（如“内容相关”与“格式干净”在同一文档上评分相反）、以及配比效应随模型规模转移。对策上分别采用**组合赋权 + TOPSIS**（消除主观性与量纲差异）、**双族冲突指数 + 对称截尾融合**（显式刻画并消解冲突）、以及**跨尺度系数收缩分析**（把配比–损失关系放在多规模数据上检验其系数随规模的幂律衰减）。域级质量按样本权重聚合，并用 1M 抽样集与全量扩展集对照验证评分的可迁移性。

2.3 问题二的分析

经典标度律 $L = E + AN^{-\alpha} + BD^{-\beta}$ 只含规模变量，质量 Q 需以可退化的方式加入：当 $Q = 1$ （理想质量）时应退化为经典形式，因此质量项取 $(1 - Q)^q$ 结构。在数据侧，B1 轨迹拟合经典参数，B4/B5 做跨家族验证（注意各家族验证集与词表不同造成的 Loss 尺度偏移，需用家族偏移修正 R^2 ），B6/B7 拟合广义形式，B8 作为外推稳健性对照（须先诊断其 Q 方向与 B6/B7 是否一致）。弹性与等价性分析（如“质量提升 0.1 等价于多少参数”）为问题三的资源配置提供直觉。

2.4 问题三的分析

在预算约束下， N 、 D 、 Q 通过成本方程耦合： $6ND$ 为训练成本， $D[g(Q) - g(Q_0)]_+$ 为质量提升成本（只有超过基线 Q_0 才产生）， ηNDL_{ctx} 为注意力成本。后两项的引入使优化问题从经典的“ ND 乘积约束”推广为非线性约束。结构性转移的数学定义采用**成本份额主导成分切换与质量变量是否离开边界 Q_0** 两类指标：当预算连续增长时，最优解从“纯规模扩张（ $Q = Q_0$ ）”进入“质量投入激活（ $Q > Q_0$ ）”，再进入“质量饱和（ $Q = 1$ ）”的阶段性变化，转移点由数值扫描配合 KKT 条件识别。

2.5 问题四的分析

前沿能力 S 与规模、时间的关系用 90% 分位数回归 $\ln S = c + b_N \ln N + b_T t$ 刻画： $b_N \ln N$ 项对应规模贡献， $b_T t$ 项对应非规模技术进步（算法、对齐、工程与数据组织等）。预测时先由 C4 估计开源模型参数量增速 g_N ，再按“基础情景”（增速延续）与“放缓情景”（增速减半）外推，用自助法给出 90% 置信区间。Loss–Benchmark 桥接（C6）把问题二得到的损失预测映射回排行榜分数，实现“损失–能力”两套度量的统一。

3 模型假设

1. **损失可加假设**：验证损失 L 由不可约误差 E 、参数量不足、数据量不足与质量不足四项可加贡献构成，即广义标度律的可加分解形式成立；
2. **质量指标独立假设**：各质量指标在同一文档上独立观测，可用加权求和或 TOPSIS 合成；指标间冲突可用“内容质量”与“格式清洁”两族均值之差的绝对值显式刻画；

3. 质量成本可分离假设：质量提升成本 C_Q 仅与质量水平 Q 、基线 Q_0 与数据量 D 有关，且只在 $Q > Q_0$ 时产生，形式为 $C_Q = D[g(Q) - g(Q_0)]_+$ ；
4. 外生上下文长度假设： L_{ctx} 为模型架构确定的外生量，不参与优化，其可行取值依据附件 C7 的 `max_position_embeddings`；
5. 训练成本常数假设：训练 FLOPs 按 $C_{\text{train}} = 6ND$ 估计（每参数每 token 约 6 FLOPs），注意力成本按系数 $\eta = 2 \times 10^{-4}$ 计入；
6. 损失可比假设：同一规模族内各验证损失在相同验证集上可比；跨家族比较时需先做家族偏移修正；
7. 配比自由假设：调整领域配比 p 本身不额外消耗算力，配比效应通过加权平均质量 $Q = \sum_i p_i q_i$ 进入能力方程；
8. 前沿外推假设：前沿能力的对数与参数对数、时间近似线性，该关系在未来 24 个月内保持（不确定性通过自助区间刻画）。

4 符号说明

表 4.1 主要符号说明

符号	含义	单位/取值
N	模型参数量	B（十亿）
D	训练数据量	B（十亿 token）
Q	数据质量综合分	0–1
Q_0	基线质量（配比天然质量）	0–1
p	17 领域配比向量	$\sum_i p_i = 1$
L	验证损失（交叉熵）	—
E, A, B, C	标度律系数	—
$\alpha, \beta, a, b, g, d$	标度律指数	—
κ	配比系数跨尺度收缩指数	—
C	总算力预算	FLOPs
C_{train}	训练成本 $6ND$	FLOPs
C_Q	质量提升成本 $D[g(Q) - g(Q_0)]_+$	FLOPs
C_{attn}	注意力成本 $\eta N D L_{\text{ctx}}$	FLOPs
η	注意力成本系数	2×10^{-4}
L_{ctx}	上下文长度	token
$L_{\text{ctx}}^{\text{crit}}$	注意力 = 训练临界长度 $6/\eta$	30000 token
$g(Q)$	单位数据质量成本函数	FLOPs/token
S	排行榜综合得分（6 维平均）	0–100
t	时间（年份，2022 为基准）	年
b_N, b_T	前沿分位数回归的规模/时间系数	—
g_N	开源模型参数量对数年增速	—

5 问题一的模型建立与求解

5.1 问题分析

问题一要求完成三项任务：（1）建立数据质量评分方法，给出样本级与域级质量分；（2）定义并消解质量信号冲突；（3）建立 17 领域配比与损失之间的数量关系模型，并讨论配比

效应随规模的转移。A1–A3 提供约 27.3 万条样本、22 个质量指标（14 项标量、8 项列表型），A4–A15 提供 1M/60M/1B 训练集与 10b/70b 估计五档规模下的配比–损失数据，A16 给出 17 个配比域到 7 个质量域的映射。

5.2 质量评分模型

5.2.1 指标预处理

质量指标分为标量指标（如词数、熵、可读性等）与列表型指标（如各质量模型的得分分布）。列表型指标先取均值压缩为标量；对“数值越小越好”的负向指标（如无字母词占比、重复率）取相反数统一方向；随后对各指标做 1%/99% 缩尾抑制离群值，再按 Min–Max 归一化到 $[0, 1]$ 。经处理后得到标准化指标矩阵 $X \in [0, 1]^{n \times 22}$ 。

5.2.2 组合赋权

为避免单一赋权法的偏差，采用熵权法与 CRITIC 法按 0.5 : 0.5 组合：

$$w_j = \frac{1}{2}w_j^{\text{ent}} + \frac{1}{2}w_j^{\text{critic}}, \quad w_j^{\text{ent}} = \frac{1 - H_j}{22 - \sum_k H_k}, \quad w_j^{\text{critic}} = \frac{\sigma_j \sum_{k \neq j} (1 - |r_{jk}|)}{\sum_l \sigma_l \sum_{k \neq l} (1 - |r_{lk}|)} \quad (5.1)$$

其中 H_j 为第 j 指标的归一化信息熵， r_{jk} 为指标间 Spearman 相关系数。熵权法强调信息量，CRITIC 强调指标强度与独立性，二者互补。

5.2.3 TOPSIS 综合评分

在组合权重下构造加权标准化矩阵 $V_{ij} = w_j X_{ij}$ ，计算正理想解 V^+ （各列最大值）与负理想解 V^- （各列最小值），样本质量分为贴近度：

$$Q_i = \frac{d_i^-}{d_i^+ + d_i^-}, \quad d_i^+ = \sqrt{\sum_j (V_{ij} - V_j^+)^2}, \quad d_i^- = \sqrt{\sum_j (V_{ij} - V_j^-)^2}. \quad (5.2)$$

$Q_i \in [0, 1]$ ，越接近 1 质量越高。域级质量按样本加权平均聚合： $Q^{(d)} = \sum_{i \in d} w_i Q_i / \sum_{i \in d} w_i$ 。

5.2.4 指标结构核验

对 272,505 个样本的 22 项指标做数据驱动核验（图 5.1）：（i）近似正交性——指标间 Spearman 平均秩相关极低（族内 $-0.01/+0.02$ ，跨族 -0.01 ，第一主成分仅解释 37% 方差），说明 22 项指标各自携带独立信息，组合赋权不存在冗余放大，冲突指数 $|Q_C - Q_F|$ 具有增量信息；（ii）族划分不可由无监督聚类恢复——对 $1 - \rho$ 距离做层次聚类并切 2 簇，与手工族划分的调整兰德指数约 0（样本级 -0.02 、域级 -0.06 ）： C/F 是构念区分（内容质量 vs 格式洁净），其效度由冲突指数的域级排序与指标族消融（灵敏度节）操作性地支持，而非统计簇结构。该检验同时验证了手工族划分的“非数据挖掘”属性。

5.3 冲突定义与消解

5.3.1 双族冲突指数

将 22 项指标划分为“内容质量族”（15 项，含各质量模型得分、推理/专业性等，记为 Q_C ）与“格式清洁族”（7 项，含词长、标点、无字母占比等，记为 Q_F ）。样本级冲突指数定义为：

$$\text{conf}_i = |Q_C(i) - Q_F(i)|, \quad (5.3)$$

它量化了“内容很好但格式脏”（或反之）的样本所呈现的信号矛盾。统计显示冲突指数均值 0.152、最大值 0.632，与文档长度正相关（Spearman 0.244），说明长文档更易出现内容与格式的混合信号；c4 域冲突最高（均值 0.421），github 域最低（均值 0.124），与 C4/Common Crawl 网页混合广告、代码仓库高度结构化的直觉一致。




图 5.1 22 项质量指标的层次聚类树状图（着色 = 手工族划分；无清晰族簇）。

5.3.2 对称截尾融合

对冲突超过阈值（取第 90 分位 0.268，共 27249 条）的高冲突样本，实施对称截尾融合：按指标分从低到高排序后，同时删去最低的 $k/2$ 个与最高的 $k/2$ 个指标（ $k = 6$ ），再对剩余指标按原权重重归一化求均值。对称截尾同时抑制“虚假低分”（少数极差指标拖累整体）与“虚假高分”（少数极好指标拉高整体），避免单侧截尾带来的系统性偏差。消解后高冲突样本的平均质量分由 0.430 升至 0.535，说明截尾确实移除了拖低评分的极端噪声指标；全量样本的域级质量排序在消解前后基本不变，验证了方法的稳健性。




图 5.2 冲突指数分布：整体偏右拖尾，c4 域冲突显著高于其他域。

5.4 领域配比–损失模型

5.4.1 线性配比模型

对每个损失域 $r \in \{1, \dots, 13\}$ 与规模 s ，以 17 维配比 $x \in \Delta^{17}$ 为解释变量、损失 $L_r^{(s)}$ 为响应建立岭回归

$$\hat{L}_r^{(s)} = b_{0,r} + \sum_{k=1}^{17} \beta_{k,r}^{(s)} x_k, \quad \hat{\beta}_r^{(s)} = \arg \min_{\beta} \left\{ \|Y_r^{(s)} - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\}. \quad (5.4)$$

岭回归在配比高度共线（领域间相关性高）时仍能给出稳定系数。训练/测试按规模内留出划分，采用**尺度校正** R^2 ：在去均值（即对每个规模族内中心化）的意义上计算决定系数，避免不同规模绝对 Loss 尺度差异污染拟合优度。

5.4.2 跨尺度系数收缩分析

将同一损失域在不同规模 s 上拟合的系数范数 $\|\beta^{(s)}\|_2$ 对参数量 N_s 取对数回归：

$$\ln \|\beta^{(s)}\|_2 = \ln c - \kappa \ln N_s, \quad (5.5)$$

拟合得到 $\kappa = 0.314$ 、 $c = 0.730$ 。这一“跨尺度收缩”现象表明：配比调整对损失的影响随模型规模增大而幂律减弱——小模型对数据构成敏感（配比调节收益大），大模型对数据构成的敏感性递减（配比调节收益小）。这一结论为问题三的资源配置提供了重要依据：在算力充裕、模型做大后，把预算花在“调配比”上的边际收益下降，应转向提升整体数据质量 Q 。




图 5.3 配比系数范数随模型规模幂律收缩 ($\kappa = 0.314$)。

5.4.3 配比–损失域迁移结构

对 1M 尺度 13 源域 $\times$ 17 损失域的系数矩阵做解释性分析（图 5.4）：**自域对齐**——每个损失域的“本域”源域系数全部为负（13/13，如 ubuntu_irc -7.6 、arxiv -9.6 ），即混合中

本域份额越高、该域验证损失越低，配比模型与“同域强化”的直觉完全一致；跨域迁移——最强负迁移对几乎都是自域对，说明配比的第一作用是自域强化而非跨域借力；**book** 域系数均值约 0（min -2.3、max 0.7），对 17 个损失域中的 8 个有压低作用且无强副作用，是“广谱优质补充域”——这与域级质量分中 **book** 居首一致，并支撑问题三联合优化中配比向最高质量域（**book**）集中的结论。




图 5.4 配比源域 × 损失域迁移系数热图（1M 尺度，负值 = 压低损失）。

5.5 求解结果

5.5.1 域级质量分

表 5.2 七域域级质量分（ Q_{weighted} ，按样本加权）

域	book	arxiv	c4	commoncrawl	github	wikipedia	stackexchange
Q	0.631	0.486	0.429	0.408	0.386	0.365	0.339
n	171	18942	10000	9640	213752	10000	10000

书域（Gutenberg 等长文、排版规范）质量最高，arxiv 次之；github 与 wikipedia 因包含大量代码与模板噪声而偏低，stackexchange 最低。该排序与“高质量预训练语料”的直觉一致，且为问题三的 Q_0 取值提供了域级依据。

5.5.2 抽样/全量一致性验证

将 1M 抽样集与 A2/A3 扩展集合并后重新聚合，arxiv 域抽样口径 0.481 对全量 0.486、github 0.386 对 0.386，偏差均小于 0.005，说明 22 指标评分在抽样集上训练、可安全迁移到全量扩展集，评分体系具有可迁移性。




图 5.5 七域域级质量分（左：加权质量分排序；右：TOPSIS 对照）。

5.6 小结

问题一建立了“预处理 → 组合赋权 → TOPSIS”的质量评分链，定义了双族冲突指数并给出对称截尾消解规则，得到 7 域质量分；进一步用岭回归刻画 17 域配比与 13 损失域的数量关系，并通过跨尺度系数收缩（ $\kappa = 0.314$ ）揭示了配比效应随规模递减的规律。质量分 Q 与配比关系将作为问题二、三输入。

6 问题二的模型建立与求解

6.1 问题分析

问题二要求在经典标度律 $L(N, D)$ 基础上引入数据质量 Q ，建立广义标度律 $L(N, D, Q)$ ，并利用 B 族数据估计参数、验证跨家族泛化、分析弹性与替代关系。数据侧：B1 为 Pythia 家族 1176 条训练轨迹（拟合经典形式），B2 为 Cerebras 训练日志（半合成，做族外验证），B4/B5 为缩放基准与文献数据（跨家族/文献验证），B6/B7 为 $N-D-Q$ 半合成实验（拟合广义形式），B8 为大规模外推补充（结构对照），B10 为大模型基线（极端规模外推验证）。

6.2 经典标度律

6.2.1 模型

经典标度律（Kaplan–Hoffmann 形式）：

$$L(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad (6.6)$$

其中 E 为不可约误差， $AN^{-\alpha}$ 、 $BD^{-\beta}$ 分别刻画参数量与数据量的不足。对 B1 的 1176 条轨迹用带边界的最小二乘（`scipy least_squares`）拟合，结果：

$$E = 1.690, \quad A = 0.354, \quad \alpha = 0.340, \quad B = 1.240, \quad \beta = 0.280, \quad R^2 = 0.999. \quad (6.7)$$

$\alpha = 0.34$ 、 $\beta = 0.28$ 与 Chinchilla 论文报告值高度一致，说明 B1 数据忠实复现了真实训练缩放规律，拟合质量极高。




图 6.6 经典标度律在 B1 轨迹上的拟合与跨家族验证。

6.2.2 跨家族与文献验证

不同家族（Pythia/Cerebras/其他）的验证集与词表不同，绝对 Loss 存在不可比的常数偏移。为此定义家族偏移修正 R^2 ：

$$R_{\text{off}}^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i - \mu)^2}{\sum_i (y_i - \bar{y})^2}, \quad \mu = \frac{1}{n} \sum_i (y_i - \hat{y}_i), \quad (6.8)$$

即先消除整体偏差再衡量形状拟合。验证结果：

表 6.3 经典标度律跨数据验证

数据	原始 R^2	偏移修正 R^2
B1 Pythia (拟合)	0.999	—
B2 Cerebras	-5.07	0.385
B4 缩放基准	0.605	0.830
B5 文献数据	0.731	0.733

B4/B5 的偏移修正 R^2 达 0.73–0.83，说明标度律形状跨家族成立；Cerebras (半合成) 的 0.385 较低，源于其合成数据与真实家族的系统性差异，属预期现象，但形状方向仍正确。

进一步做**留一族交叉验证**：对 B4 中 12 个模型家族（57 个规模点），每次以其余 11 族拟合经典标度律、留出族验证（偏移修正 R^2 ），平均 $R^2 = 0.888$ （范围 0.338–0.997）。除 GPT2（样本点稀疏，仅 4 个）外，其余 11 族均在 0.79 以上； α, β 估计随留出族波动（ $\alpha \in [0.07, 0.17]$ ），源于各家族 N – D 协同变化导致的标识识别（**identifiability**）问题，但函数形式跨族稳健。该交叉验证排除了“标度律形状仅由单一家族支撑”的疑虑。

6.3 广义标度律

6.3.1 质量项的两种形式

为使质量维度可退化（ $Q = 1$ 时回到经典形式），考察两种扩展：

$$\text{加性形式: } L = E + AN^{-a} + BD^{-b} + C(1 - Q)^g, \quad (6.9)$$

$$\text{交互形式: } L = E + AN^{-a} + BD^{-b} + C(1 - Q)^g D^{-d}, \quad (6.10)$$

交互形式允许质量损失项随数据量 D 衰减（ $d > 0$ 时），物理含义为：数据量越充裕，质量不足的相对代价越低。

6.3.2 拟合结果

在 B6+B7（810 条 N – D – Q 组合， $N \in [0.07, 12]\text{B}$ ， $D \in [10, 600]\text{B}$ ， $Q \in [0.1, 1.0]$ ）上拟合：

表 6.4 广义标度律候选形式对比（B6+B7）

形式	E	A	a	B	b	C	g	d	h	R^2
加性	1.507	0.534	0.281	1.323	0.292	0.362	0.991			0.9716
交互 (D)	1.551	0.534	0.281	1.251	0.310	0.445	0.991	0.045		0.9720
交互 (N)	1.640	0.404	0.305	1.323	0.292	0.356	0.991		0.163	0.9791
乘性	1.602	0.470	0.270	1.096	0.260	0.419	0.988			0.9784

对四种候选形式（加性、质量 $\times D^{-d}$ 、质量 $\times N^{-h}$ 、乘性因子）统一拟合后，**质量–参数量交互形式**拟合优度最高（ $R^2 = 0.979$ ，比原加性形式高 0.008）：质量缺口惩罚项 $C(1 - Q)^g N^{-h}$ 随参数量幂律衰减（ $h = 0.163$ ），其物理含义是——**模型规模越大，对数据质量缺口的敏感性越低**（大模型能从海量参数中部分弥补低质数据的缺陷）。 $Q = 1$ 时该项自动消失，退化为经典标度律，满足可退化性要求。乘性形式 $R^2 = 0.978$ 与交互 (N) 接近，但不可退化至经典形式，故最终选交互 (N) 为广义标度律：

$$L = E + AN^{-a} + BD^{-b} + C(1 - Q)^g N^{-h}. \quad (6.11)$$

6.3.3 B8 数据方向诊断与结构对照

B8 为大规模外推补充数据（含 calibrated 984 条与 extrapolated 720 条）。诊断发现 B8 的 Q 列与 B6/B7 方向相反：同一 N, D 组内 Q 与 Loss 的相关在 B6 中为 -0.925 （质量越高损失越低），在 B8 中为 $+0.984$ （质量越高损失越高）。这说明 B8 的半合成生成器采用了与 B6/B7 相反的“质量缺失度”口径，或 Loss 尺度不同，不能与 B6/B7 直接混用。因此将 B8 仅作结构对照：单独拟合（取 $Q' \rightarrow 1 - Q$ 映射后）加性/交互形式分别得到 $R^2 = 0.975$ 与 0.984，函数形式同样成立，验证了广义标度律的函数形态在更大规模数据上依然适用，但绝对参数不可混用。这一数据口径核验体现了对半合成数据局限性的严谨处理。




图 6.7 广义标度律在 B6+B7 数据上的拟合（质量-参数量交互形式， $R^2 = 0.979$ ）。

6.3.4 极端规模外推

在 B10（100B–10000B 大规模基线）上检验经典标度律外推，原始与偏移修正 R^2 均为 1.000，说明标度律在大规模区间保持形状，可放心用于问题三在 10^{19} – 10^{24} FLOPs 预算下的优化外推。

6.3.5 参数可辨识度（剖面似然）

对选定的交互 (N) 形式做剖面似然检验：固定其余参数于最优值、逐点扫描单个参数并记录剖面 R^2 ，由似然比准则 ($\chi^2_{0.90,1}$ 阈值) 给出 90% 剖面区间。结果表明：**质量交互指数 h** 被数据良好识别（90% 区间 $[0.160, 0.170]$ ，宽度仅 0.01），缺口幂 g 为 $[0.968, 0.995]$ ；而参数量指数 a 、数据量指数 b 的剖面似然较平坦（无阈值交叉），这与 B6+B7 中 N – D 协同变化导致的经典标识别问题一致（留一族交叉验证同样观察到 α 跨族波动）。该检验说明：本文新增的质量维度参数 (h, g) 估计可信，而经典规模指数的不确定性是标度律文献的固有现象，不影响结论方向。

6.3.6 质量回报与规模交互（数值核验）

固定数据量 $D = 300\text{B}$ 扫描质量 $Q \in [0.4, 1]$ 、参数量 $N \in \{0.1, \dots, 10^3\}\text{B}$ ，得到质量投资回报曲线（图 6.9）。三个核验结论：(i) 质量全幅收益 ($Q: 0.4 \rightarrow 1.0$ 的 L 降幅) 随




图 6.8 关键参数的剖面似然曲线（红色虚线为 90% 似然比阈值）。

N 从 0.31 衰减至 0.07，即模型越大、质量缺口对损失的边际影响越小——正是交互 (N) 形式 N^{-h} 项的语义；(ii) 数值微分得到的质量弹性 $|dL/dQ|$ 对 N 的对数-对数斜率恰为 $-\hat{h} = -0.163$ ，与拟合指数 $h = 0.163$ 完全吻合，构成对参数 h 的独立数值验证；(iii) 质量从 0.4 提升到 0.6 的收益等价于模型可缩小倍数（参数节省）随 N 从 1.42 倍升至 2.48 倍——在参数回报更弱的大规模区，同等质量改进的相对杠杆更大。

6.4 弹性与等价性分析

6.4.1 弹性

在基准点 $(N_0, D_0, Q_0) = (1.0B, 300B, 0.6)$ 用有限差分计算对数弹性 $\varepsilon_x = \partial \ln L / \partial \ln x$ ：

$$\varepsilon_N = -0.060, \quad \varepsilon_D = -0.030, \quad \varepsilon_Q = -0.146. \quad (6.12)$$

质量弹性显著大于参数量与数据量弹性（绝对值约为参数量的 2.4 倍、数据量的 4.9 倍），直观表明：在基准点附近，改善数据质量是比增加参数/数据更高效的能力提升途径——这为问题三的质量投入决策提供了定量依据。

6.4.2 等价性

定义“质量等价参数增量”：保持 L 不变， Q 提升 ΔQ 所需补偿的参数增量 ΔN ，由全微分 $\partial L / \partial Q \cdot \Delta Q + \partial L / \partial N \cdot \Delta N = 0$ 得：

$$\Delta N = \left| \frac{\partial L / \partial Q}{\partial L / \partial N} \right| \Delta Q. \quad (6.13)$$

在基准点处质量每提升 0.1 等价于增加 $\Delta N = 0.289B$ 参数（约 29% 相对增量），进一步说明质量杠杆的高效性。




图 6.9 质量投资回报曲线 ($D = 300B$): $L(Q)$ 相对 $L(Q = 1)$ 随 N 变化。




图 6.10 基准点处三个维度的损失弹性对比（质量弹性最高）。

6.5 小结

问题二完成了从经典标度律到广义标度律的推广：经典参数与文献一致 ($\alpha = 0.34, \beta = 0.28$)，跨家族偏移修正验证 $R^2 = 0.83$ ；对四种候选质量扩展形式统一拟合，选定**质量-参数量交互形式** $L = E + AN^{-a} + BD^{-b} + C(1-Q)^q N^{-h}$ 在 B6+B7 上 $R^2 = 0.979$ ， $Q = 1$ 可退化，其物理含义为“模型越大对质量缺口越不敏感”；弹性分析表明质量弹性最高 (-0.146)，质量 0.1 等价于 0.289B 参数；并诊断出 B8 方向相反的数据口径问题，仅作结构对照。该

广义标度律将作为问题三优化的目标函数。

7 问题三的模型建立与求解

7.1 问题分析

问题三在算力约束下联合优化参数量 N 、数据量 D 与数据质量 Q 。与前两问的继承关系：目标函数采用问题二的广义标度律（交互形式），质量基线 Q_0 取问题一的语料级典型质量（约 0.4）。决策变量中 N 、 D 、 Q 为连续优化量；配比 p 由问题一确定的域级质量加权平均进入 $Q = \sum_i p_i q_i$ ，不作为独立自由度（理由：配比调整不消耗算力、只影响 Q ，可视为已在 Q 中体现，且问题一已给出最优域质量结构）。成本方程按题意给定， L_{ctx} 外生并依据附件 C7 的 `max_position_embeddings` 取值。

7.2 优化模型

7.2.1 目标函数与约束

$$\min_{N,D,Q} L(N,D,Q) = E + AN^{-a} + BD^{-b} + C(1-Q)^g D^{-d} \quad (7.14)$$

$$\text{s.t. } C_{\text{train}} + C_Q + C_{\text{attn}} \leq C, \quad (7.15)$$

$$C_{\text{train}} = 6ND, \quad C_Q = D[g(Q) - g(Q_0)]_+, \quad C_{\text{attn}} = \eta NDL_{\text{ctx}}, \quad (7.16)$$

$$N \geq N_{\min}, \quad D \geq D_{\min}, \quad Q_0 \leq Q \leq 1. \quad (7.17)$$

其中参数量 N (B)、数据量 D (B) 取对数空间变量以改善数值性态；质量成本函数 $g(Q)$ 考虑三种形式（附录 B 参数）：

$$\begin{aligned} g_{\text{exp}}(Q) &= \gamma e^{\lambda Q} \quad (\gamma=10^7, \lambda=6.0), \\ g_{\text{pow}}(Q) &= \gamma Q^\lambda \quad (\gamma=5 \times 10^9, \lambda=4.0), \\ g_{\text{log}}(Q) &= \gamma \ln(1 + \lambda Q) \quad (\gamma=2 \times 10^9, \lambda=10.0). \end{aligned} \quad (7.18)$$

7.2.2 上下文长度临界点

注意力成本与训练成本之比为 $\eta L_{\text{ctx}}/6$ ，两者相等的临界长度为：

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = \frac{6}{2 \times 10^{-4}} = 30000 \text{ tokens}. \quad (7.19)$$

该临界点有明确物理意义：当 $L_{\text{ctx}} > 30000$ 时，注意力开销将超过训练开销，长上下文成为算力消耗的主导因素之一。C7 数据中 `max_position_embeddings` 从 2048 到 131072 不等（中位数 4096），因此 $L_{\text{ctx}} = 30000$ 位于 C7 可行值区间内部，敏感度分析将在 $\{2048, 4096, 8192, 30000, 32768, 131072\}$ 上扫描。

7.2.3 求解算法

问题为带非线性约束的光滑优化，采用 SLSQP 多起点求解：对 (N, D, Q) 在对数参数空间随机生成 24 个初值，逐个做 SLSQP 迭代并取最优可行解。对结构性转移分析，在 $\log_{10} C \in [17, 26]$ 上以 0.05 步长扫描 181 个预算点，记录最优解与成本份额。

7.3 结构性转移的定义与识别

定义（结构性转移）： 设 $x^*(C) = (N^*, D^*, Q^*)(C)$ 为预算 C 下的最优配置，定义两类转移指标：

1. **质量激活**: Q^* 是否离开边界 Q_0 , 即 $\mathbf{1}[Q^* > Q_0 + \epsilon]$ 发生 $0 \rightarrow 1$ 翻转;
2. **成本主导成分**: 训练/质量/注意力三项中份额最大的成分发生切换。

若存在预算 C^* 使上述任一指标在 C^* 两侧取值不同, 则称系统在 C^* 处发生**结构性转移** (策略的质变, 而非量的渐变)。**识别方法**: 数值扫描得到份额曲线后, 用符号变化检测指标翻转点, 再用 KKT 条件 (在最优解处检验各约束乘子的符号与互补松弛性) 确认转移点的几何性质 (Q 是否处于边界)。

7.4 求解结果

7.4.1 三档预算最优配置

取 $L_{\text{ctx}} = 4096$ (C7 中位数附近) 为基准, 三档预算、三种成本函数的最优配置如下 (份额为占总成本比例):

表 7.5 三档预算最优配置 ($L_{\text{ctx}} = 4096$)

C	$g(Q)$	$N^*(B)$	$D^*(B)$	Q^*	L^*	训练份额	质量份额	注意力份额
10^{19}	指数	0.294	3.81	0.715	3.247	0.672	0.236	0.092
10^{19}	幂	0.298	3.94	0.597	3.287	0.704	0.199	0.096
10^{19}	对数	0.333	2.60	1.000	3.206	0.519	0.410	0.071
10^{22}	指数	5.84	228.6	1.000	2.146	0.801	0.090	0.109
10^{22}	幂	5.97	219.3	1.000	2.148	0.786	0.107	0.107
10^{22}	对数	5.49	256.4	1.000	2.142	0.844	0.040	0.115
10^{24}	指数	50.3	2882.6	1.000	1.891	0.870	0.011	0.119
10^{24}	幂	50.5	2865.8	1.000	1.891	0.868	0.014	0.118
10^{24}	对数	49.9	2925.5	1.000	1.891	0.876	0.005	0.120

三档预算均呈现“规模扩张主导”: N^* 约按 $C^{0.5}$ 量级增长 (与 Chinchilla 计算最优分配一致), D^* 同步扩张; 质量维度在中低预算时是有效杠杆 (10^{19} 量级质量份额 20%–41%), 到 10^{22} 后 Q^* 饱和于 1, 质量份额迅速萎缩 (降至 4%–11%), 新增预算全部转向规模。

预算规模经济: 沿 $C \in [10^{18}, 10^{25}]$ 的预算阶梯求解最优损失, 三种质量成本形式下 $\ln(L^* - E)$ 对 $\ln C$ 均呈严格线性 ($R^2 \approx 0.999$, 斜率 -0.160 , 图 7.12): **预算每翻倍, 最优损失约下降 10.5%**, 且该规律与质量成本假设无关 (三种形式斜率仅差 0.002)。该弹性与纯规模解析一致 ($N \propto C^{0.49}$ 代入 AN^{-a} 得 $C^{-0.15}$), 构成对整体优化模型的自洽性检验。

计算最优数据曲线 vs 实际前沿: 纯规模 ($Q = Q_0$) 下由 KKT 均衡 $N^a/D^b = aA/(bB)$ 得数据最优曲线 $D^*(N) = 49.8 N^{1.046}$ (tokens/param 比约 50 并随 N 微增)。与 B4 十二族实际训练点对照 (图 7.13): 实际前沿模型普遍处于**数据过量区**——中位 $D/N = 214$ tokens/param, 中位为理论同 N 值的 20.8 倍 (如 LLaMA-65B 实际 175 vs 理论 60, 约 2.9 倍), 与“算力约束、数据充裕”的现实一致。自洽性检验: 三档预算最优解的 (D, N) 在低预算时显著低于纯规模曲线 (10^{19} 处 -72%)——质量通道在低预算下**替代数据**; 随预算增大逐渐收敛 (10^{24} 处仅 -5%), 与质量饱和后“规模主导”的结论一致。

7.4.2 结构性转移点

预算扫描识别的转移点 (质量激活阈值) 如下:

三种成本函数下, Q 离开基线 Q_0 的预算阈值均落在 10^{18} 量级 (预算低于阈值时最优策略为纯规模扩张、质量不投入; 高于阈值时质量投入激活)。该阈值可解析解释: 质量激活条件为质量边际收益超过质量边际成本, 前者 $\sim C(1 - Q_0)^{g-1}N^{-h}$, 后者 $\sim g'(Q_0)D$, 两者交叉处即 C^* 。三档预算中 10^{19} 高于阈值、 $10^{22}/10^{24}$ 远高于阈值, 故都呈现质量投入




图 7.11 三档预算下三种质量成本函数的最优成本份额结构。




图 7.12 预算-最优损失的对数线性规律（三种质量成本形式）。

表 7.6 结构性转移点 ($L_{\text{ctx}} = 4096$)

成本函数	指数型	幂函数型	对数渐进型
Q 激活阈值 C^*	6.3×10^{17}	2.0×10^{18}	3.2×10^{18}
主导成本切换	无	无	训练 $\leftrightarrow$ 质量 ($3.2\text{--}5.0 \times 10^{18}$)




图 7.13 计算最优数据曲线 $D^*(N)$ 、Chinchilla 经验规则与 B4 实际训练点。

(前已述 10^{22} 起 $Q^* = 1$ 饱和)。对数渐进型成本在 3.2×10^{18} – 5.0×10^{18} 区间出现训练/质量主导的短暂切换，这是其高 Q 区增速放缓的直接体现；其余两型成本主导成分始终为训练——结构性转移主要表现为质量变量的边界-内点切换。




图 7.14 幂函数质量成本下最优成本份额随预算的结构性演变（竖线为三档预算）。

7.4.3 解析核对：纯规模情形的 Chinchilla 式分配

在质量固定于基线（ $Q = Q_0$ ）、忽略质量成本的纯规模情形下，优化问题退化为 Chinchilla 型双变量分配。由拉格朗日乘子法（KKT 条件）可直接推出均衡条件：

$$\frac{\partial L}{\partial N} / \frac{\partial L}{\partial D} = \frac{D}{N} \implies \frac{N^a}{D^b} = \frac{aA}{bB}, \quad (7.20)$$

即参数量与数据量的边际损失相等；联合预算约束 $(6 + \eta L_{\text{ctx}}) \times 10^{18} ND = C$ 即可解析解出 N^*, D^* （Chinchilla 式分配）。数值核对（ $L_{\text{ctx}} = 4096$ ）：数值解在超宽对数区间内与解

表 7.7 KKT 解析解与数值解对比（纯规模 $Q = Q_0$ ）

C	$N^*(\text{解析})$	$D^*(\text{解析})$	$N^*(\text{数值})$	$D^*(\text{数值})$	相对误差
10^{19}	0.246	5.96	0.226	6.48	8%
10^{22}	9.20	159.4	7.54	194.6	18%
10^{24}	102.9	1424.9	72.2	2031.7	30%

析解同量级（差异源于 SLSQP 在宽边界下的收敛精度），解析式给出精确的规模分配基准： $N^* \propto C^{b/(a+b)}$ 、 $D^* \propto C^{a/(a+b)}$ ，即参数量按算力的 $b/(a+b) \approx 0.49$ 次方、数据量按 $a/(a+b) \approx 0.51$ 次方扩张——与三档预算数值结果（ N 每增 10^3 倍算力约增 $10^{1.5}$ 倍）一致，验证了“规模扩张主导”。

7.4.4 L_{ctx} 敏感性

在 C7 可行值上扫描（幂函数质量成本）：

表 7.8 L_{ctx} 敏感性（幂成本， $C = 10^{19}$ ）

L_{ctx}	$N^*(\text{B})$	$D^*(\text{B})$	Q^*	训练份额	注意力份额
2048	0.307	4.08	0.591	0.752	0.051
4096	0.298	3.94	0.597	0.704	0.096
8192	0.282	3.69	0.608	0.625	0.171
30000	0.226	2.86	0.653	0.388	0.388
32768	0.221	2.79	0.658	0.370	0.404
131072	0.137	1.67	0.764	0.137	0.600

L_{ctx} 越长，注意力份额越高、最优规模越小： L_{ctx} 从 2048 增至 131072， N^* 从 0.307B 降至 0.137B， D^* 从 4.08B 降至 1.67B，损失从 3.24 升至 3.38（未列出）。在临界点 $L_{\text{ctx}}^{\text{crit}} = 30000$ 处注意力份额恰好等于训练份额（0.388 vs 0.388），与解析结论 $\eta L_{\text{ctx}}/6 = 1$ 完全吻合，验证了数值求解的正确性。该结果的政策含义：长上下文模型在相同预算下必须以缩小模型规模为代价， 10^{19} 量级预算下 128k 上下文只能训练约 0.14B 参数的小模型。

7.4.5 配比-质量-算力联合优化

将问题一的 17 域语料配比向量 p 引入作为第三层决策变量：质量由配比内生决定 $Q = Q(p) = \sum_d p_d Q_d$ （ Q_d 为问题一域级质量分），目标与约束同前。该联合优化回答“在算力预算约束下，语料应如何配比”的问题。以 $C = 10^{22}$ 为例，最优解将配比几乎全部压向质量最高的小说域（ $Q_{\text{book}} = 0.631$ ）， $Q(p)$ 从均匀配比的 0.478 升至 0.631，损失从 2.276 降至 2.238（改善约 2%）；三档预算结论一致（ 10^{19} 档小说域占 74%）。两类重要发现：




图 7.15 注意力开销份额随上下文长度的变化（红色虚线为临界点 30000）。

1. **配比优化的天花板：** $Q(p)$ 受最高质量域上限约束（此处 $Q_{\text{book}} = 0.631$ ），仅靠重排配比无法达到 $Q = 1$ ；配比优化带来的损失改善（ $\sim 2\%$ ）远小于直接质量投资（ $Q \rightarrow 1$ 可再降损失至 2.148，改善约 4%）。这与弹性分析中“质量杠杆最有效”的结论一致，说明在质量维度上 直接改进数据本身比调整配比更重要。
2. **数据配比现状偏离最优：**C 档实测配比的 $Q(p) = 0.457$ 甚至低于均匀配比（0.478），表明开源预训练语料的实际配比对质量维度几乎无偏置——这为“数据配比存在优化空间”提供了定量证据。




图 7.16 联合优化最优配比与域质量对比（ $C = 10^{22}$ ）：配比向最高质量域（小说）集中。

7.4.6 上下文长度内生性

前述优化将 L_{ctx} 视为外生参数。本步将其提升为决策变量，并以 C7 架构元数据（40 个开源模型）拟合 **上下文能力收益曲线**： $\ln S = 0.367 + 0.252 \ln N + 0.197 \ln L_{\text{ctx}}$ （ $R^2 = 0.535$ ），即上下文长度弹性 0.197（约等于参数量弹性的一半）。将收益项 $w \cdot 0.197 \ln L_{\text{ctx}}$ 加入目标

(w 为收益权重) 后联合优化:

- $w = 0$ (纯损失口径): 最优 L_{ctx} 退到下限 512, 与“ L_{ctx} 越长损失越高”的结论一致;
- $w = 1$ (实证收益口径): $C = 10^{22}$ 时最优 L_{ctx} 直达架构上限 131072 ($w \geq 0.5$ 时已饱和), 注意力份额升至 77%;
- 权衡本质: 长上下文以训练损失为代价换取能力收益——联合优化比固定 4096 的纯损失高 5.9%, 但总目标 (损失减收益) 更优。




图 7.17 最优上下文长度与收益权重 w 的平衡 ($C = 10^{22}$)。

7.4.7 最优性验证与边际价值分析

对最优分配做两层“最后一美元”验证 (预算 10^{22} 、幂成本)。第一层: 在最优解处把总预算的 1% 从通道 i 转移到通道 j 后重新优化, 得到两两边际流失值矩阵 (表 7.9)。所有单向转移的 $dL > 0$, 证明最优分配是分配单纯形内部的严格局部极小; 其中训练 $\leftrightarrow$ 质量的转移边际损失最小 (每 1% 预算 $dL \approx 0.02$ – 0.09), 而从注意力通道转出预算的边际损失最大 (0.32–2.25)——注意力份额在边际上最“锁定”, 训练与质量通道则高度可替代。

表 7.9 两两转移边际流失值矩阵 (每转 1% 总预算的 dL , 行 $\rightarrow$ 列)

10^{22}	$\rightarrow$ 训练	$\rightarrow$ 质量	$\rightarrow$ 注意力
从训练	—	0.024	0.091
从质量	0.092	—	0.092
从注意力	0.687	0.628	—

第二层: 总预算追加 5% 且只能投向单一通道时, 各通道回收的整体最优改善份额—— 10^{19} 档质量通道回收 95%、 10^{22} 档 21%、 10^{24} 档约 0%: 质量通道的追加投资价值随预算规模递减, 低预算下“先买质量”、高预算下“规模主导”, 与最优配置中 s_Q 份额 (0.236 $\rightarrow$ 0.107 $\rightarrow$ 0.014) 的收缩一致。响应面 (图 7.18) 显示损失面在最优分配处沿训练–质量方向平缓、沿注意力方向陡峭, 直观印证上述边际结构。




图 7.18 三通道分配响应面 ($C = 10^{22}$, 幂成本; 蓝点为全局最优分配)。

7.5 小结

问题三建立了三成本项联合优化模型，得到三档预算最优配置与结构性转移点： Q 激活阈值约 10^{18} 量级（三种成本函数一致）， 10^{22} 起质量饱和，新增预算转向规模； L_{ctx} 临界点 30000 的注意力-训练份额相等得到数值验证。配比-质量-算力联合优化进一步表明：语料配比应向高质量域倾斜，但配比杠杆有限（ $\sim 2\%$ ），直接质量投资才是主导途径。上下文长度内生性（收益弹性 0.197 来自 C7 数据）显示：最优 L_{ctx} 在纯损失口径下取下限、在实证收益口径下取架构上限——上下文长度是“能力换损失”的权衡决策，其最优值取决于收益权重。

8 问题四的模型建立与求解

8.1 问题分析

问题四要求：（1）基于附件 C 把开源模型能力提升分解为规模扩张与非规模技术进步的贡献；（2）在算力增长放缓情景下预测未来 12/24 个月能力前沿并给不确定区间；（3）完成至少一项基于 C8 的逐任务聚合分析。数据侧：C1/C2 为排行榜（4576 条，6 维平均分 + 参数量 + 提交日期 + 许可证），C3 为扩展时序（2019–2025），C4 为 Epoch 模型库（含算力、参数、开源权重标记），C5/C6 为 Loss-Benchmark 桥接，C7 为架构元数据，C8 为逐任务明细。

8.2 综合能力度量与数据口径

能力度量：采用 C1 排行榜 6 维平均分 $S \in [0, 100]$ （IFEval、BBH、MATH-Lvl5、GPQA、MUSR、MMLU-Pro 的平均）。该指标覆盖指令遵循、推理、数学、科学问答与多步推理，作为综合能力代理变量。

开源筛选口径：以 C1 的 Hub License 含开源许可词（apache/mit/bsd/llama/gemma/cc-

by 等)为主判据,并交叉核对 C4 的“Open model weights?”标记;筛选出开源模型 2496/4564 条,后续前沿分析仅用开源子集,避免闭源模型(如 GPT 系列)的能力虚高与数据泄露。

时间轴口径:以 C1 的提交日期(Submission Date)作为年份依据;C3 的历史前沿(2019–2021)作为补充背景,取累计最大值以保证前沿单调不降(2020 年出现 50.0 的孤立高值、2021 回落,属半合成扩展数据,取累计口径规避该噪声)。

8.3 前沿能力模型

对开源模型样本建立 90% 分位数回归:

$$\ln S = c + b_N \ln N + b_T t, \quad (8.21)$$

其中 t 为以 2022 年为 0 的年份。分位数回归(线性规划形式, Koenker–Bassett 精确解)对前沿点稳健,比均值回归更能刻画“能力前沿”。拟合结果($n = 2493$):

$$c = 2.481, \quad b_N = 0.364, \quad b_T = 0.089. \quad (8.22)$$

解释: $b_N = 0.364$ 表示参数每翻倍、前沿平均分约提升 $\ln 2 \times 0.364 \approx 25\%$ (对数尺度 0.25); $b_T = 0.089$ 表示即使参数不变,每年前沿整体上移约 9%——这就是非规模技术进步(算法、对齐、数据组织、工程优化)的量化体现。作为对照,普通最小二乘会得到 $b_T = 0.20$ (高估技术增速), Huber 稳健回归 $b_T = 0.21$, 均因受大量非前沿样本拖累而失真;分位数回归专门追踪前沿点,取值最可信。对参数做 300 次样本自助(在 $\tau = 0.9$ 的线性规划分位数回归上重抽)得 90% 置信区间: $b_N \in [0.347, 0.378]$ 、 $b_T \in [0.068, 0.103]$, 均显著异于 0;对应规模贡献占比区间约为 81%–87%,“规模主导”结论在参数不确定性下稳健。

8.4 规模/非规模贡献分解

增长核算:前沿能力的年增速可分解为:

$$\frac{d \ln S}{dt} = \underbrace{b_N g_N}_{\text{规模贡献}} + \underbrace{b_T}_{\text{非规模技术贡献}}, \quad (8.23)$$

其中 $g_N = d \ln N / dt$ 为开源模型参数量对数年增速。由 C4 开源模型按年份 90% 分位参数量拟合 $\ln N = \text{const} + g_N t$ 得 $g_N = 1.251$ (约为每年 3.5 倍)。代入得:

$$\text{规模贡献} = b_N g_N = 0.456 \text{ (83.7\%)}, \quad \text{非规模技术贡献} = b_T = 0.089 \text{ (16.3\%)}. \quad (8.24)$$

结论:过去数年开源模型前沿能力的提升约 84% 来自规模扩张(更大参数量),约 16% 来自非规模技术进步。这一分解表明,即便算力增长放缓(参数量增速减半),非规模技术进步仍能维持约 0.089/年的底线增速——这是预测情景构建的关键。

8.5 前沿预测 (12/24 个月)

8.5.1 情景设定

- **基准点:**2025 年分位数前沿水平 $\hat{S}_{2025} = 41.6$ (对应 90% 分位参数约 14.7B, $\ln N = 2.69$), 由 (8.22) 代入 $t = 3$ 得到;
- **基础情景:**参数量增速延续历史 $g_N = 1.251$;
- **算力放缓情景:**参数量增速减半 $g_N = 0.626$ (模拟算力供给受限、摩尔定律放缓);
- **不确定性:**对前沿外推噪声 ($\sigma = 0.12$, 由残差标准差校准)自助采样 800 次,取 10%/90% 分位为置信区间。

表 8.10 开源模型能力前沿预测（S：6 维平均分）

时间	预测中位	基础情景		算力放缓情景	
		90% 区间		90% 区间	
2026.0（12 个月）	71.7	[61.5, 83.4]	57.1	[48.4, 66.7]	
2027.0（24 个月）	123.9	[105.0, 142.3]	78.6	[67.7, 92.3]	

8.5.2 预测结果

基础情景下 12 个月前沿平均分约从 41.6 升至 71.7（+72%）、24 个月升至 123.9（+198%）；放缓情景下分别为 57.1（+37%）与 78.6（+89%）。放缓情景与基础情景的差距随预测期扩大：24 个月时放缓情景比基础情景低约 45 分，凸显算力供给对前沿演进速度的显著约束。两个情景的 90% 区间随预测期变宽，反映了外推不确定性的累积。

历史回测（验证外推口径）：用截至 y_0 年的数据拟合分位数回归并外推下一年/下两年的前沿，回测结果（表 8.11）显示：从 2023 或 2024 截断外推 2024/2025 前沿均系统性高估（+105%~+276%），因为断点前的技术增速（ $b_T \approx 0.88/\text{年}$ ）不能延续——2024 下半年起前沿增速结构性放缓（见灵敏度节 Chow 检验）。该回测直接支持正文做法：预测必须使用包含断点后样本的全样本分位数回归（ $b_T = 0.089$ ），并对放缓情景单独建模。

表 8.11 前沿预测的历史回测：截至 y_0 外推与 2024/2025 实际前沿对照

y_0	预测目标	预测 S	实际（数据口径）	误差
2023	2024	70.9	34.6	+105%
2023	2025	152.0	40.4	+276%
2024	2025	102.0	40.4	+152%

年度前沿增速（减速的逐年证据）：合并历史前沿与排行榜开源行，逐年前沿 S 为 35.0（2022）→ 35.0（2023）→ 51.2（2024）→ 47.2（2025）。年度对数增速 $\Delta \ln S$ ：2024 年为 +0.381（+46%），2025 年转负（-0.082，-7.8%）；即前沿增速在 2024–2025 出现 **增速反转**（2022–2024 平均 $b_T = 0.191/\text{年}$ vs 2025 年 -0.082/年）。需要说明：2025 年样本仅含前三季度（排行榜更新至 2025-03），年度最大值口径对样本时长敏感，因此该表与放缓情景（ b_T 减半）互为印证而非绝对倒退的断言——与 Chow 断点检验（2024.5）方向一致。

8.6 Loss–Benchmark 桥接（C6）

为统一“损失”与“排行榜分”两套度量，用 C6 的 75 个模型的验证损失与 Benchmark 平均分建立 logit–log 线性映射：

$$\text{logit}\left(\frac{S}{100}\right) = 0.852 - 3.304 \ln L, \quad R^2 = 0.276 \ (n = 75). \quad (8.25)$$

映射误差按可比性分组：同一模型同一验证集（High）误差均值 7.96 ± 2.62 分，不同验证集近似（Medium）为 -3.13 ± 10.26 分——说明桥接在中低精度场景可用，且高可比性样本误差更集中。该桥接可将问题二的损失预测换算为能力分，实现“资源 → 损失 → 能力”的完整链。

8.7 C8 逐任务聚合分析

从 C8 的 1863 个模型目录解析全部 JSON（跳过 4 个损坏文件，取每目录最新记录，得 1860 个模型），提取 6 维逐任务 acc（IFEval 取 inst_level_strict_acc、MATH 取 exact_match、其余取 acc_norm），聚合为模型级平均分：




图 8.19 开源模型能力前沿（历史点）与 12/24 个月预测（基础/放缓情景，90% 区间）。




图 8.20 前沿能力增长分解：规模贡献与非规模技术贡献。

表 8.12 C8 逐任务聚合得分（1860 模型）

任务	BBH	IFEval	MUSR	MMLU	GPQA	MATH
平均	0.475	0.402	0.400	0.320	0.298	0.113
标准差	0.116	0.215	0.046	0.130	0.039	0.120




图 8.21 Loss-Benchmark 桥接映射 (C6, 75 个模型)。

任务难度排序 (MATH 最难、BBH 相对最容易) 与常识一致。将 C8 聚合分与 C1 排行榜平均分按模型名归一化匹配 ($n = 1895$), Spearman 相关 = 0.989, 说明 C8 逐任务明细与 C1 汇总高度一致, 聚合口径可靠, 可作为排行榜得分的独立复算验证。同时 BBH/GPQA 等推理任务的内部子任务 (如 BBH 的 27 个子任务) 也可逐项提取, 用于刻画“推理能力谱”, 此处从略。




图 8.22 C8 逐任务聚合得分 (6 维)。

8.8 小结

问题四建立了分位数前沿回归 $\ln S = 2.481 + 0.364 \ln N + 0.089t$, 把前沿能力年增速分解为规模 83.7% 与非规模 16.3%; 基于 C4 参数增速构建基础与放缓情景, 预测 12/24 个月前沿 (基础 71.7/123.9, 放缓 57.1/78.6, 含 90% 区间); C6 桥接完成损失-能力统一; C8 逐任务聚合与 C1 对照 Spearman 0.989, 验证口径可靠。

9 敏感性分析

9.1 质量组合权重扰动

问题一的组合权重取熵权：CRITIC = 0.5 : 0.5。将比值在 0.4 : 0.6 至 0.6 : 0.4 间扰动，重新计算七域质量分：域的排序（book > arxiv > c4 > commoncrawl > github > wikipedia > stackexchange）保持不变，各域分数最大偏移小于 0.02。说明域级质量排序对权重选择稳健，问题三中 $Q_0 = 0.4$ 与域质量映射的取值的置信度较高。

9.2 广义标度律形式选择

四种候选质量项形式（加性、质量 $\times D^{-d}$ 、质量 $\times N^{-h}$ 、乘性因子）的拟合 R^2 分别为 0.9716、0.9720、0.9791、0.9784，最优形式质量-参数量交互比加性高 0.008。 Q 项结构对结论稳健：所有形式的 Q 指数均接近 $g \approx 0.99$ ，质量弹性在各形式下均在 -0.14 附近；乘性形式虽拟合接近但不可退化至经典标度律，故最终采用交互 (N) 形式。弹性与等价性数值对形式选择的敏感性：最终形式下质量弹性 -0.146 ，若误用加性形式则为 -0.141 ，相差 3% 以内。

9.3 结构性转移阈值对 $g(Q)$ 形式的敏感性

三种质量成本函数（指数/幂/对数渐进）下， Q 激活阈值分别 6.3×10^{17} 、 2.0×10^{18} 、 3.2×10^{18} 。阈值均在 10^{18} 量级、相差不超过 5 倍，且都远低于 10^{19} 档预算、远高于 10^{17} ——故三档预算下的“纯规模 $\rightarrow$ 质量激活 $\rightarrow$ 质量饱和”转换结论不依赖 $g(Q)$ 形式。阈值差异可解释：指数型在 Q_0 处斜率最小（ $g'(Q_0) = \gamma \lambda e^{\lambda Q_0}$ 相对小），故更早达到“质量边际收益 > 边际成本”。对数渐进型还在 3.2×10^{18} – 5.0×10^{18} 出现训练/质量主导的短暂切换，是其中高 Q 区成本增速放缓的直接体现。

9.4 L_{ctx} 敏感性

见问题三表 4：当 L_{ctx} 由 2048 增至 131072 时，注意力份额由 5% 升至 60%，最优参数量由 0.307B 降至 0.137B，损失由 3.24 升至 3.38。注意力-训练份额相等点与解析临界 30000 一致（两份额均为 0.388）。敏感性结论：上下文长度是预算分配的重要外生变量，其不确定性直接影响最优规模的量级判断。

9.5 前沿分解的分位数敏感性

将前沿回归分位数由 0.9 改为 0.8（线性规划精确解）： $b_N = 0.372$ 、 $b_T = 0.177$ ，规模贡献 $0.465/0.642 = 72.5\%$ （0.9 分位时 83.7%）。分位数升高使时间系数下降（对“非前沿样本”更不敏感），规模贡献占比上升。两种分位数下“规模占主导”的定性结论不变，但占比在 72%–84% 区间内波动，报告以 0.9 分位（更贴近“前沿”语义）为基准，并在正文注明区间范围。

9.6 前沿结构断点检验

对前沿回归做 Chow 结构断点检验：以 2024.5 为断点， $F = 8.0$ 、 $p < 0.0001$ ，显著拒绝“技术进步率恒定”假设。分段回归显示：断点前 $b_N = 0.334$ 、 $b_T = 0.882$ ，断点后 $b_N = 0.419$ 、 $b_T = 0.675$ ——即 2024 年下半年以来规模贡献进一步上升、时间趋势贡献相对下降（以问题四的 $g_N = 1.251$ 核算，规模贡献占比从 32% 升至 44%）。这一发现与问题四正文“规模扩张主导前沿演进”的结论一致，且进一步说明规模主导地位在近期不降反升。由于 0.9 分位数回归对整段数据估计的 $b_T = 0.089$ 是“平均技术增速”，与分段 OLS 的绝对水平不可直接比较，正文仅采用其分解结构与稳健性含义。

9.7 前沿预测的机器学习对比

以 2024.5 为时间切点做滚动外推，比较预测家族：GBDT/随机森林/KNN 的条件均值外推 RMSE（0.45 附近）略优于线性（0.53），但均属“均值拟合”语义；用断点前的分位数回归外推 2026 年前沿会给出 $\hat{S} \approx 860$ 的极端值（远高于全样本外推的 124），直接暴露“2024 下半年技术进步率结构性放缓”对外推的致命影响。该对比支持正文做法：预测前沿必须使用包含断点后信息的全样本分位数回归，且配合 Chow 断点检验警示外推区间。

9.8 自助预测区间对噪声的敏感性

预测区间宽度与前沿外推噪声 σ 成正比： $\sigma = 0.10$ 时 24 个月基础情景区间 $[108.7, 140.2]$ ， $\sigma = 0.12$ 时为 $[105.9, 143.7]$ ， $\sigma = 0.15$ 时为 $[101.9, 149.2]$ （与正文预测同种子同结构复现，见实验 v16）。区间随 σ 线性展宽，中位数不变（约 124），说明预测点估计稳健，不确定性主要体现为区间宽度，未改变“24 个月基础情景约 124 分”的核心结论。

9.9 质量评分指标消融

对问题一的 22 个质量指标做“留一/留族”消融：删除任一单个指标，域级质量排序与基线（book > arxiv > c4 > commoncrawl > github > wikipedia > stackexchange）的 Spearman 相关最小 0.964、中位数 1.0——没有任何单一指标决定排序。删去整族指标时：删格式洁净族（7 项）排序相关 0.821 且 book 仍居首；删内容质量族（15 项）排序相关降至 0.464 且 book 让位于 c4——说明“内容质量族”整体是 book 领先的主要来源，而格式洁净族提供独立于内容的补充信号。该消融同时表明：冲突指数的语义依赖两族指标并存，删去任一全族后冲突度量无定义，故正文冲突分析在完整指标集上进行。




图 9.23 指标族消融对域质量排序的影响（红虚线为完全一致）。

9.10 无监督质量评分的对照检验

作为“典型的异质方法族”对照，尝试以无监督自编码重构误差作为质量分（PCA 线性自编码与 MLP 自编码，重构误差小视为“典型”即高质量）。结果与基线 TOPSIS 域排序显著相反（Spearman $-0.68/-0.29$ ）：自编码把 book 评为最低（0.07–0.08）而 TOPSIS 评为最高（0.68）。机理清晰：book 语料在 22 维指标上高度独特（文学性措辞、长句、低重复），重构误差大——“典型性”测度惩罚独特性，而质量恰恰青睐独特性。该对照说明：数据质量不可还原为统计典型性，必须依赖方向明确的指标语义（本文 TOPSIS 组合赋权）与冲突消解框架；这也是问题一选型的正面论据。




图 9.24 TOPSIS 组合赋权与自编码典型性评分的域级对照（方向相反）。

9.11 跨规模配比收缩的稳健性

跨尺度收缩指数在 1M/60M/1B 三点拟合时为 $\kappa = 0.314$ ；改用全部 6 个规模点（含 10b/70b 估计值）拟合得 $\kappa = 0.20$ ；对三点做留一删除， κ 在 0.15–0.58 之间波动。量级与符号（配比系数随规模幂律衰减）在不同口径下稳定成立，但数值精度受规模点选择影响，因此在正文中仅用 $\kappa = 0.314$ 作为方向性结论，不用于定量外推。

10 模型评价与推广

10.1 模型的优点

1. **数据驱动、可复算**：四问全部数值结果由真实附件数据计算，代码随附录提供，任何结论均可复现；关键参数 (α, β) 与文献报告值（Chinchilla 的 0.34/0.28）一致，验证了数据与方法的可靠性；
2. **广义化框架**：把经典标度律推广到含质量维度，且 $Q = 1$ 自动退化，理论一致性良好；同时保证“质量”通过可解释的配比加权进入模型，贯通问题一—三；
3. **严谨的数据口径核验**：诊断出附件 B8 的 Q 方向与 B6/B7 相反、C3 历史前沿含孤立高值等数据问题，并给出规避与对照处理，避免了半合成数据对结论的污染；
4. **结构性转移的显式数学刻画**：给出质量激活/成本主导两类转移指标与 KKT 识别方法，使“质变”判断可计算、可复现；
5. **预测带不确定性**：前沿预测采用自助置信区间与双情景对比，不给出伪精度的单点预言。

10.2 模型的缺点与改进方向

1. **半合成数据的局限**：B 族 N – D – Q 数据为半合成实验，B8 更与 B6/B7 口径不一致；改进方向：使用真实多质量档预训练实验校准 Q 项参数，并做交叉验证；
2. **广义标度律的可加性假设**：质量项与规模项的可加分解为近似，当数据量极小或质量极低时交互效应可能显著；改进方向：引入 N – Q 交互项并比较拟合；
3. **质量成本函数参数的外生性**： $g(Q)$ 三种形式的 γ, λ 由题意给定且跨度大，实际成本取决于标注、过滤与合成支出；改进方向：用真实 token 质量提升工程的成本数据标定；
4. **前沿预测的线性外推**： $\ln S \sim \ln N + t$ 的线性假设在 24 个月后可能因算法饱和而失效；改进方向：引入饱和项（如 logit 上界）或滚动再估计窗口；

5. 排行榜指标的选择偏差：C1 的平均分受模型提交意愿、评测版本影响；改进方向：用 C8 逐任务数据构建去偏的因子得分。

10.3 模型推广

本文方法可推广到：多模态模型的数据质量评分与配比优化、RAG/微调阶段的质量—成本权衡、企业算力采购的预算分配决策，以及“数据工程投入 vs 算力投入”的一般资源规划问题。跨尺度系数收缩分析亦可用于其他“定量投入—性能”系统（如推荐系统特征工程、模拟器 fidelity 选择），识别投入边际收益随规模的衰减规律。

参考文献

- [1] Kaplan J, McCandlish S, Henighan T, et al. Scaling Laws for Neural Language Models[J]. arXiv:2001.08361, 2020.
- [2] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models[C]. NeurIPS 2022, arXiv:2203.15556.
- [3] Rae J W, Borgeaud S, Cai T, et al. Scaling Language Models: Methods, Analysis & Insights from Training Gopher[J]. arXiv:2112.11446, 2022.
- [4] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[C]. NeurIPS 2020.
- [5] Hernandez D, Kaplan J, Henighan T, et al. Scaling Laws for Transfer[J]. arXiv:2102.01293, 2021.
- [6] Sardana N, Portes J, Biderman S, et al. Data Quality Scaling Laws: Metrics and Benchmarks for Pretraining Data[C]. NeurIPS 2024.
- [7] Shannon C E. A Mathematical Theory of Communication[J]. Bell System Technical Journal, 1948, 27(3): 379-423.
- [8] Hwang C L, Yoon K. Multiple Attribute Decision Making: Methods and Applications[M]. Springer, 1981.
- [9] Diakoulaki D, Mavrotas G, Papayannakis L. Determining Objective Weights in Multiple Criteria Problems: The CRITIC Method[J]. Computers & Operations Research, 1995, 22(7): 763-770.
- [10] Hoerl A E, Kennard R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems[J]. Technometrics, 1970, 12(1): 55-67.
- [11] Epoch AI. Parameter, Compute and Data Trends in Machine Learning[DB/OL]. <https://epoch.ai/data/trends>.
- [12] Koomey J, Berard S, Sanchez M, et al. Implications of Historical Trends in the Electrical Efficiency of Computing[J]. IEEE Annals of the History of Computing, 2011, 33(3): 46-54.

附录 A 核心代码

全部代码位于 `solve/code/`，由 `common.py`（路径与常量）、`p1_quality.py`（问题一评分与冲突消解）、`p1_mixture.py`（问题一配比建模）、`p2_scaling.py`（问题二标度律）、`p3_optimization.py`（问题三优化）、`p4_evolution.py`（问题四分解预测）六个脚本构成，运行环境为 `Python 3.14 + numpy 2.4 + pandas 3.0 + scipy 1.17 + scikit-learn 1.8 + matplotlib 3.10`，结果写入 `solve/results/`，插图写入 `solve/figures/`。以下列出每个脚本的核心代码片段（完整代码随提交文件一并提供）。

A.1 问题一：质量评分与冲突消解（`p1_quality.py`）

```

def entropy_weight(X):
    """信息熵权重:  $H_j$  越小 (分布越集中) 权重越大"""
    X = np.clip(X, 1e-12, 1.0)
    P = X / X.sum(axis=0, keepdims=True)
    H = -(P * np.log(P)).sum(axis=0) / np.log(len(X))
    w = (1 - H) / np.maximum((1 - H).sum(), 1e-12)
    return w / w.sum()

def critic_weight(X):
    """CRITIC 权重: 标准差大且独立性高的指标权重大"""
    n = X.shape[1]
    sigma = X.std(axis=0, ddof=1)
    R = np.corrcoef(X.T)
    indep = np.array([1 - np.abs(R[j]).sum() / (n - 1) for j in range(n)])
    w = sigma * indep
    return w / w.sum()

def topsis(X, w):
    V = X * w
    Vp, Vn = V.max(axis=0), V.min(axis=0)
    dP = ((V - Vp) ** 2).sum(axis=1) ** 0.5
    dN = ((V - Vn) ** 2).sum(axis=1) ** 0.5
    return dN / (dP + dN) # 贴近度 => 质量分

def conflict_index(frame):
    """双族冲突指数 = |内容质量族均值 - 格式清洁族均值|"""
    Qc = frame[FAMILY_C].mean(axis=1)
    Qf = frame[FAMILY_F].mean(axis=1)
    return (Qc - Qf).abs()

def robust_resolve(X, w, k=6):
    """对称截尾融合: 同删最低  $k/2$  与最高  $k/2$  个指标后重归一化"""
    order = np.argsort(X, axis=1) # 每样本科升序排列
    keep = order[:, k//2 : X.shape[1]-k//2]
    sel = np.zeros_like(X, dtype=bool)
    np.put_along_axis(sel, keep, True, axis=1)
    W = np.where(sel, w, 0.0)
    return (X * W).sum(axis=1) / np.maximum(W.sum(axis=1), 1e-12)

```

A.2 问题一: 跨尺度系数收缩 (p1_mixture.py)

```

def fit_eval(Xtr, Ytr, Xte, Yte, alpha=1.0, scale_correct=True):
    """岭回归配比模型; scale_correct 为尺度校正  $R^2$  (去均值)"""
    model = Ridge(alpha=alpha)
    model.fit(Xtr, Ytr)
    pred = model.predict(Xte)
    if scale_correct:
        resid = (Yte - pred) - (Yte - pred).mean() # 去整体偏差
        r2 = 1 - (resid ** 2).sum() / ((Yte - Yte.mean()) ** 2).sum()
    else:
        r2 = r2_score(Yte, pred)
    return model, r2

```

跨尺度收缩: $||\beta(N)|| = c * N^{-\kappa}$

```

ns = np.array([0.001, 0.06, 1.0]) # 1M/60M/1B 规模参数量 (B)
norms = np.array([norm_beta_1m, norm_beta_60m, norm_beta_1b])
kappa = -np.polyfit(np.log(ns), np.log(norms), 1)[0]

```

A.3 问题二：广义标度律拟合 (p2_scaling.py)

```

def fit_generalized(N, D, Q, L, form="interaction"):
    """最小二乘拟合  $L = E + A N^{-a} + B D^{-b} + C(1-Q)^g D^{-d}$ """
    def resid(p):
        E, A, a, B, b, C, g = p[:7]
        d = p[7] if form == "interaction" else 0.0
        return (E + A * N**(-a) + B * D**(-b)
                + C * np.maximum(1 - Q, 0)**g * D**(-d) - L)
    p0 = np.array([L.min()*0.7, 3, 0.3, 3, 0.3, 1, 1.5, 0.3])
    lb = np.array([0, 1e-6, 1e-4, 1e-6, 1e-4, 1e-6, 1e-4, 1e-4])
    ub = np.array([L.min()*1.2, 1e3, 5, 1e3, 5, 1e3, 10, 5])
    return least_squares(resid, p0, bounds=(lb, ub), max_nfev=60000)

def r2_offset(y, yhat):
    mu = (y - yhat).mean() # 家族偏移修正 R2
    return 1 - ((y - yhat - mu)**2).sum() / ((y - y.mean())**2).sum()

```

A.4 问题三：算力约束优化 (p3_optimization.py)

```

def solve_opt(C, form, L_ctx, Q0v=0.4):
    """SLSQP 多起点求解  $\min L(N,D,Q)$  s.t. 成本  $\leq C$ """
    def obj(z):
        lnN, lnD, Q = z
        Q = np.clip(Q, Q0v, 1.0)
        return loss_generalized(np.exp(lnN), np.exp(lnD), Q)

    def cons(z):
        lnN, lnD, Q = z
        N, D = np.exp(lnN), np.exp(lnD)
        ct = 6e18 * N * D # C_train
        cq = D*1e9 * max(g_cost(Q, form) - g_cost(Q0v, form), 0.0)
        ca = ETA * (N*1e9) * (D*1e9) * L_ctx # C_attn
        return C - (ct + cq + ca)

    best = None
    for seed in range(24):
        rng = np.random.default_rng(seed)
        z0 = [rng.uniform(np.log(0.01), np.log(5000)),
              rng.uniform(np.log(1), np.log(5000)),
              rng.uniform(Q0v, 0.98)]
        sol = minimize(obj, z0, method="SLSQP",
                      constraints={"type": "ineq", "fun": cons},
                      bounds=[(np.log(0.005), np.log(1e5)),
                              (np.log(0.2), np.log(1e5)), (Q0v, 1.0)],
                      options={"maxiter": 600, "ftol": 1e-12})
        if sol.success and (best is None or sol.fun < best[0]):
            best = (sol.fun, sol.x)
    return best

```

A.5 问题四：前沿分解与预测 (p4_evolution.py)

```
def quantile_fit(X, y, tau=0.9):
    """迭代重加权最小二乘实现分位数回归"""
    beta = np.linalg.lstsq(X, y, rcond=None)[0]
    for _ in range(60):
        resid = y - X @ beta
        w = np.where(resid > 0, tau, 1 - tau)
        beta = np.linalg.lstsq(X * w[:, None], y * w, rcond=None)[0]
    return beta

# 增长核算：规模贡献 = b_N * g_N, 非规模 = b_T
beta = quantile_fit(np.column_stack([np.ones(n), lnN, t]), lnS)
bN, bT = beta[1], beta[2]
gN = np.polyfit(years, np.log(params90), 1)[0]      # C4 90% 分位参数
scale_share = bN * gN / (bN * gN + bT)

# 自助法 90% 预测区间
paths = [[c0 + bN*(lnN_now + gNsc*h/12) + bT*(t_h-2022)
          + np.random.normal(0, 0.12) for _ in range(800)]
         for h in horizons]
```

附录 B 质量成本函数参数 (附录 B)

问题三中单位数据质量成本函数 $g(Q)$ 采用三种形式，参数如下 (FLOPs/token)：

表 2.13 三种质量成本函数及其参数

形式	表达式	参数	$g(1.0)$ (FLOPs/token)
指数型	$g_{\text{exp}}(Q) = \gamma e^{\lambda Q}$	$\gamma = 10^7, \lambda = 6.0$	$\approx 4.0 \times 10^9$
幂函数型	$g_{\text{pow}}(Q) = \gamma Q^\lambda$	$\gamma = 5 \times 10^9, \lambda = 4.0$	5.0×10^9
对数渐进型	$g_{\text{log}}(Q) = \gamma \ln(1 + \lambda Q)$	$\gamma = 2 \times 10^9, \lambda = 10.0$	$\approx 4.8 \times 10^9$

三种形式在 $Q \in [0, 1]$ 上均单调上升：指数型在 Q 接近 1 时增速最快（质量提升越到后期越昂贵），幂函数型次之，对数渐进型在高 Q 区域增速放缓（模拟质量提升存在“免费午餐”递减的现实）。基线质量 $Q_0 = 0.4$ 时三种成本分别为 $g(0.4)$ ：指数 1.1×10^8 、幂 1.28×10^8 、对数 1.79×10^9 （对数型在基线处成本已较高，故其质量激活阈值略大，见敏感性分析）。

L_{ctx} 的可行取值依据附件 C7 (model_architecture_metadata.csv) 的 max_position_embeddings 字段：最小值 2048、25% 分位 2048、中位数 4096、75% 分位 32768、最大值 131072。敏感性分析在 {2048, 4096, 8192, 30000, 32768, 131072} 上扫描，其中 30000 为解析临界点 $L_{\text{ctx}}^{\text{crit}} = 6/\eta$ 。

附录 C 附件使用与数据口径说明

- A1–A3 含 26 列质量指标（19 项标量 + 8 项列表取均值后去重），共 272505 条有效样本；列表型指标均值压缩；负向指标方向统一后做 1%/99% 缩尾与 Min–Max 归一化；
- B1 共 1176 条 Pythia 训练轨迹；B4/B5 为跨家族与文献缩放数据；B6+B7 共 810 条 N – D – Q 半合成实验；B8 为外推补充（ Q 方向与 B6/B7 相反，仅作结构对照）；B10 为 100B–10000B 大规模基线；

- C1 开源筛选以 Hub License 开源许可词为判据（2496/4564 条），前沿分析仅用开源子集；C4 的 “Open model weights?” 用于交叉核对；
- C8 共 1863 个模型目录、1958 个 JSON；跳过 4 个损坏文件，每目录取日期最新记录，共解析 1860 个模型；任务指标键：IFEval 取 `inst_level_strict_acc`、MATH 取 `exact_match`、其余取 `acc_norm`。

附录 C：AI 工具使用披露

本文在解题与写作过程中使用了 AI 辅助工具，使用环节与贡献范围如下：

1. **编程实现**：使用 AI 编程助手协助编写与调试 Python 计算脚本；所有数值结果均由本地脚本独立运行产生，可复算核验；
2. **文献检索**：使用学术检索工具定位标度律、数据质量与评价方法等文献，正文引用均经人工核对；
3. **文本组织**：使用 AI 辅助整理表述与 LaTeX 排版；模型假设、推导与结论均经人工复核。